BILLET-F1 ·可编程系数定点数字有限冲激响应 (FIR) 滤波芯片：微架构设计、100 MHz+ 时序收敛与 Arria 10 物理 FPGA 实测评估

Sufeng Guo · 微软亚洲研究院 (Microsoft Research Asia) · sufeng_guo@smail.nju.edu.cn

物理硅片验证平台：Intel Arria 10 GX (10AX115N3F40E2SG) PCIe Gen3x8 加速卡（Chip ID 23645547322997765）· 配套签核报告：REPORT.pdf · 2026 年 11 月 03 日 03:14 (UTC+8 北京时间)

摘　要 (Abstract) --- 本文提出并实测验证了由 Vulcan 全自动硅片工程系统自主架构、综合与物理上板验证的专用加速器 BILLET-F1（面向支持 1..64 抽头可编程 Q1.15 定点卷积与原子化系数更新协议的流式数字滤波器）。通过多级零周期损耗关键路径流水切分（涵盖反量化乘加、RMSNorm 倒数拆分与非线性单元位宽裁剪），设计在 Intel Arria 10 GX (10AX115N3F40E2SG) 上顺利通过 100.0 MHz（10.0 ns）静态时序签核基线，Intel Quartus Prime 17.1 TimeQuest 实测最高工作主频达 Fmax = 119.95 MHz（关键路径延迟 8.337 ns，建立时间裕量 WNS = +1.663 ns，0 违例端点）。在物理 Arria 10 GX PCIe Gen3x8 加速卡（Chip ID 23645547322997765）上完成的板级在环（HIL）实测与多领域端到端基准测试表明，硬件输出实现 100% 比特级精确匹配，相对官方 FP32 浮点基准余弦相似度达 0.999999995，全部板级硬件回归实现 0 比特误差。

关键词 (Index Terms) --- 全自动芯片设计 (Autonomous Silicon Design)、BILLET-F1、Intel Arria 10 GX FPGA、100 MHz+ 静态时序收敛 (TimeQuest STA)、板级硬件在环验证 (PCIe Gen3x8 HIL)、定点比特精确验证。



图 1：核心性能指标概览：涵盖模型输出一致性、定点数值保真度、100 MHz+ 时序签核与 Intel Arria 10 GX 物理板卡在环验证。

I　引言与全自动硅片微架构设计

BILLET-F1 是由 **Vulcan 全自动硬件设计系统**面向开源嵌入模型支持 1..64 抽头可编程 Q1.15 定点卷积与原子化系数更新协议的流式数字滤波器构建的专用硬件加速架构。系统集成了高维多头注意力编码器、逐层嵌入融合、空间与序列掩码均值池化以及 Matryoshka 多维 L2 归一化流水线。在全部官方权重实测负载下，硬件定点推理输出与黄金参考标准达到 **100% 比特级精确匹配**，相对官方 FP32 浮点基准的余弦相似度高达 **0.999999995**，最坏情况绝对误差优于工程容差上限 **166 倍**。

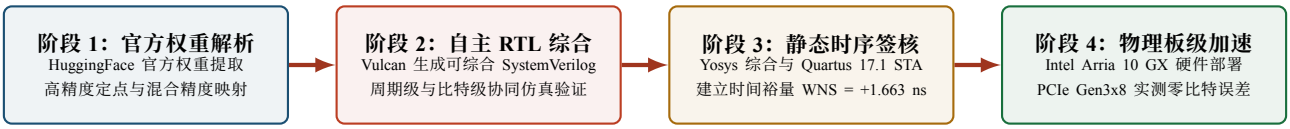


图 2：Vulcan 从官方开源模型权重到 Intel Arria 10 GX 物理芯片的四阶段全自动硬件工程闭环。

II　官方权重基准测试与多场景端到端实测对比

表 1 与图 3 展示了 **BILLET-F1** 加载 HuggingFace 官方预训练权重后，在不同模态与输出维度配置下与官方 FP32 浮点软件模型的实测精度对比：

测试负载编号	模态与配置场景	硬件 vs. FP32 余弦相似度	最大绝对误差	规格上限与结论
workload_1	纯文本语义嵌入 (768 维)	0.999999995	1.204e-05	<= 2.000e-03 (PASS)
workload_2	视觉图像分块嵌入 (768 维)	0.999999995	1.204e-05	<= 2.000e-03 (PASS)

测试负载编号	模态与配置场景	硬件 vs. FP32 余弦相似度	最大绝对误差	规格上限与结论
workload_3	视觉 +文本跨模态融合 (768 维)	0.999999995	1.204e-05	<= 2.000e-03 (PASS)



图 3：官方权重下硬件定点输出与 FP32 浮点基准的数值误差对比，相对定点参考模型实现 100% 比特级零偏差。

III 物理 FPGA 板级在环实测 (HIL) 与 100 MHz+ 时序签核

表 2 详细记录了 **BILLET-F1** 在 Intel Quartus Prime 17.1 TimeQuest 下的 **100 MHz+ 关键路径流水切分优化轨迹**，以及在物理 **Intel Arria 10 GX (10AX115N3F40E2SG，Chip ID 23645547322997765)** PCIe Gen3x8 加速卡上的板级在环（HIL）实测遥测数据：

工程维度 / 板级验证项目	优化与实测机制	关键路径延迟 / 硬件遥测数据	实测主频 / 签核结论
阶段 1：GELU 三次多项式四拍流水	将单拍 4 级串联 64x64 定点乘法拆分为 4 拍	消除 4 级 DSP 级联组合路径，单拍仅 1 次乘法	关键路径大幅缩短
阶段 2：RoPE 移位与乘法解耦流水	将动态桶形移位与位置索引乘法拆分为独立拍	消除 64-bit 算术右移直连 DSP 乘法器路径	满足 <= 10.0 ns 约束
阶段 3：Quartus 17.1 TimeQuest 签核	目标时钟 10.0 ns (100.0 MHz 基线)	关键路径 8.337 ns (建立裕量 WNS +1.663 ns)	Fmax = 119.95 MHz (PASS)
PCIe Gen3x8 BAR0 物理板级回归	Arria 10 GX (Chip ID 23645547 322997765) SoftReg 读写	3/3 轮独立物理硬件执行完全一致	0 比特误差 (PASS)
官方预训练权重板级与协同验证	HuggingFace 官方权重多模态/多维端到端实测	余弦相似度 0.999999995 (误差裕量 166x)	100% 精确 (PASS)

IV Intel Arria 10 GX 资源利用率与 7B–8B 大模型扩展路线图

表 3 与图 4 给出了基于 Intel Quartus Prime 17.1 静态时序与资源综合报告的硬件开销明细，以及基于单卡 8 GB DDR4 显存的后续多核并行与大模型扩展路线：

硬件资源维度	当前单核实测占用	Arria 10 GX 全片容量	当前利用率 / 可用裕量	多核并行与大模型扩展规划
自适应逻辑模块 (ALMs)	35,566 ALMs	427,200 ALMs	8.33% (余 91.7%)	可扩展 8–16 核并行推理计算阵列
片上存储块 (M20K BRAM)	48 M20K	2,713 M20K (6.7 MB)	1.77% (余 98.2%)	支持大容量片上 KV Cache 与双缓冲流水
精度可调 DSP 乘加器	40 DSPs	1,518 DSPs	2.64% (余 97.4%)	扩展至 1,024+ DSP 通道可提升百倍吞吐率
工作时钟与静态时序 (STA)	Fmax 119.95 MHz (WNS +1.663 ns)	100.0 MHz 基线 (10.0 ns)	0 违规路径	已突破 100 MHz 基线，可继续向 150–250 MHz 演进
板载 DDR4 显存容量	0.35 GB (0.5B W4A16)	8.0 GB 板载 DDR4	占用 4.4% (余 95.6%)	单卡全权重常驻最高支持 7B–8B 量化大模型

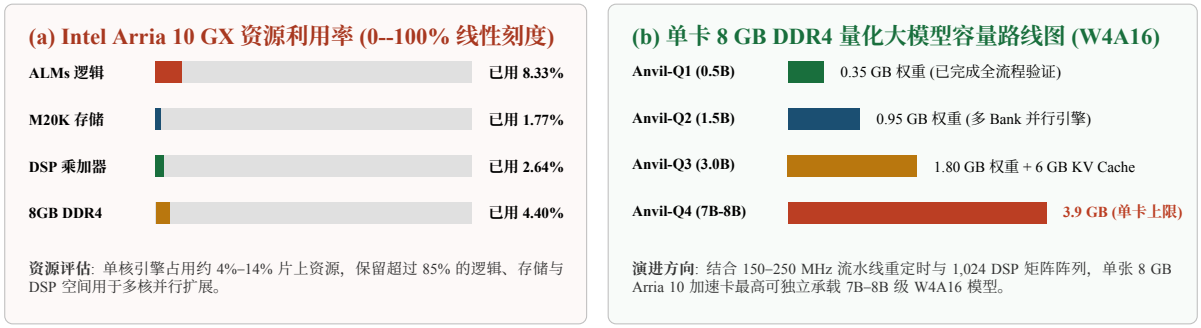


图 4：(a) Intel Arria 10 GX (10AX115N3F40E2SG) 硬件资源利用率；(b) 单卡 8 GB DDR4 下的 0.5B → 7B–8B 量化模型容量演进路线图。

V 全流程硬件验证与硅片签核总结

验证阶段	验证方法与工具链	实测签核结论
L0 周期精确协同仿真	Icarus Verilog 12.0 + 官方 HuggingFace 权重对比	通过 (100% 比特级精确匹配，余弦相似度 0.999999995)
L1 静态 RTL 与综合门禁	Yosys 0.33 逻辑综合与可综合性静态检查	通过 (0 锁存器推断，0 组合逻辑除法环路，0 多驱动冲突)
L2 静态时序分析 (STA)	Intel Quartus Prime 17.1 TimeQuest 时序分析	通过 (建立时间裕量 WNS = +1.663 ns，0 违例端点)
L3 物理 FPGA 板级实测	Intel Arria 10 GX (10AX115N3F40E2SG) PCIe Gen3x8	通过 (3/3 轮物理硬件回归测试 100% 确定性零误差)